José Luis Rativa Medina

Ingénieur IA | Ingénieur Logiciel

Paris, France · jrativamedina@gmail.com · linkedin.com/in/jrativamedina · +33 06 29 27 13 47

PROFIL

Ingénieur IA et Ingénieur Logiciel avec une expérience concrète dans la conception et le déploiement de systèmes d'IA générative et agentique : architectures RAG, distillation de LLM, mémoire conversationnelle et agents vocaux temps réel. Solides bases en génie logiciel (TypeScript, React, Node.js, Python), avec une expérience de recherche en modèles génératifs, vision par ordinateur et sécurité IoT. Habitué au travail en environnement agile et aux workflows de développement augmentés par l'IA.

FORMATION

Institut Polytechnique de Paris – Télécom SudParis Évry, France
Diplôme d'ingénieur, Voie d'approfondissement Data et IA 2024–2026
Cours pertinents : Vision par ordinateur, Deep Learning, Probabilités pour le Machine Learning, Apprentissage par renforcement, Modèles génératifs à grande échelle pour le NLP et le traitement de la parole, Gestion de données relationnelles et distribuées, Processus stochastiques, Éthique et droit de l'IA et de la science des données.

Universidad Nacional de Colombia Bogotá, Colombie
Ingénierie des Systèmes et Informatique 2020–2024
Cours pertinents : Calcul, Algèbre linéaire, Génie logiciel, Architecture logicielle, Introduction aux systèmes intelligents, Programmation orientée objet, Structures de données, Compilateurs et langages de programmation, Algorithmique, Gestion de projet.

EXPÉRIENCE

ARY S.A.S Palaiseau, France
Stagiaire Ingénieur IA Mars 2026 – Septembre 2026

— Contribution à la conception et au développement end-to-end d'agents conversationnels vocaux, de l'architecture au déploiement, en intégrant reconnaissance et synthèse vocale temps réel pour des interactions naturelles et à faible latence.
— Conception et implémentation d'architectures RAG et de composants de mémoire conversationnelle, permettant aux agents d'exploiter les bases de connaissances des clients (vectorisation, orchestration) et de maintenir une continuité contextuelle sur des échanges longs et multi-tours.
— Distillation de connaissances de Mistral Large vers un modèle étudiant Qwen 0.5B pour la classification d'intention utilisateur, suivie d'une quantization et d'une optimisation WebLLM/WebGPU pour permettre une inférence légère côté client.
— Développement d'un modèle de lip-sync léger au format ONNX par distillation de connaissances depuis MuseTalk, avec une architecture convolutionnelle compacte et remplacement du VAE de MuseTalk par TAESD pour réduire les besoins mémoire et de calcul en déploiement WebGPU.

Universidad Nacional de Colombia À distance
Ingénieur Logiciel Novembre 2023 – Août 2026

— Contribution à l'architecture et au développement d'une plateforme web de pré-inscription des étudiants à l'examen national Saber Pro (Icfes), au service d'un processus d'évaluation académique fiable et scalable.
— Contribution à l'architecture et à la conception d'un système d'auto-évaluation pour les programmes de licence et de master, permettant l'évaluation et le suivi des programmes académiques.
— Conception de schémas de bases de données et maintenance continue de systèmes d'information, garantissant intégrité des données, fiabilité et continuité opérationnelle.

PROJETS ACADÉMIQUES PERTINENTS

— **Reconstruction d'objets 3D par modèles de diffusion** *(Python, PyTorch)* – Application de modèles de diffusion génératifs pour reconstruire des objets 3D à partir de coupes 2D.
— **Identité préservant la vie privée pour l'IoT** *(Hyperledger Fabric, Blockchain, IoT)* – Conception et implémentation d'une architecture décentralisée d'identité et de contrôle d'accès pour environnements IoT.
— **TiendaUn** *(Docker, RabbitMQ, REST/GraphQL, React, Express.js)* – Conception et implémentation d'une architecture microservices événementielle pour une plateforme e-commerce universitaire.
— **Segmentation humaine 3D** *(PyTorch)* – Développement de méthodes de deep learning pour la segmentation de silhouettes humaines dans des scènes 3D.

COMPÉTENCES

Programmation : Python, TypeScript, JavaScript, Java
Développement IA : Claude Code, OpenCode, workflows de développement augmentés par l'IA
IA/ML : PyTorch, Hugging Face Transformers, LangChain, ONNX, WEBLLM, RAG, orchestration d'agents IA
Web : React, Node.js, Express.js, FastAPI, Django
Données : PostgreSQL, Supabase, MySQL, MongoDB, pgvector, Pinecone
Cloud & Outils : AWS, GCP, Docker, Git, Jira
Langues : Espagnol (langue maternelle), Anglais (C1), Français (C1)
Certification : AI Agent Developer, Coursera
Compétences non techniques : Résolution de problèmes, esprit analytique, communication efficace, travail d'équipe et adaptabilité.